

SpaceX Falcon 9 — Data Science Capstone

- Predicción del éxito de aterrizaje de la primera etapa.
- Jesús Eduardo Cota Heiras.
- Repositorio: <https://github.com/JesusCH25/testpo>

Executive Summary

- 90 lanzamientos en el dataset analítico; Class=1 indica éxito y Class=0 no éxito.
- Tasa global de éxito: 66.67%.
- El éxito aumenta a través del tiempo y varía por órbita y sitio.
- Se comparan cuatro clasificadores y se documentan métricas y matriz de confusión.

Introduction — problema

- SpaceX utiliza reutilización de primera etapa para reducir costos.
- Objetivo: predecir Class usando características de misión.
- Variables clave: sitio, payload, órbita, número de vuelo y características del booster.

Data Collection — API

- Requests obtiene JSON de SpaceX API.
- JSON se normaliza con `pandas.json_normalize`.
- Se filtran lanzamientos Falcon 9 y se exportan variables relevantes.

Data Collection — Web Scraping


- Requests + BeautifulSoup/read_html para tablas históricas.
- Se limpian encabezados, notas y tipos.
- Salida: spacex_web_scraped.csv.

Data Wrangling

- 90 filas $\times$ 19 columnas en dataset_part_2.
- Class se construye desde Outcome.
- La muestra contiene 60 éxitos y 30 no éxitos.
- Se conserva el dataset one-hot de 83 variables para ML.


EDA — lanzamientos por sitio

- CCAFS SLC 40: 55 lanzamientos.
- KSC LC 39A: 22.
- VAFB SLC 4E: 13.




EDA — resultados de aterrizaje

• True ASDS: 41; None None: 19; True RTLS: 14; False ASDS: 6; True Ocean: 5; False Ocean: 2; None ASDS: 2; False RTLS: 1.




EDA — éxito por órbita

- GTO 51.85%; ISS 61.90%; MEO 66.67%; PO 66.67%; LEO 71.43%; VLEO 85.71%.
- ES-L1, GEO, HEO y SSO tienen 100%, pero con muy pocas observaciones.




EDA — Flight Number / Payload

- Los vuelos iniciales concentran fallos.
- La probabilidad de éxito aumenta con la experiencia operacional.
- El payload debe analizarse junto con órbita y sitio.



EDA — tendencia temporal

- La tasa aumenta desde 2013 y se mantiene alta hacia 2019–2020.
- El gráfico del notebook calcula la tasa directamente con ``groupby(Year).Class.mean()``.



La figura es una representación de la tendencia documentada; el notebook genera la serie exacta al ejecutarse.

EDA with SQL — resultados

- GROUP BY LaunchSite → 55, 22 y 13 lanzamientos por sitio.
- GROUP BY Class → 30 no éxitos y 60 éxitos.
- SUM(PayloadMass) y AVG(PayloadMass) permiten cuantificar carga total y promedios.
- AVG(Class) por año produce la tasa anual de éxito.

EDA with SQL — consultas clave

Consulta	Propósito
SELECT DISTINCT LaunchSite	Identificar sitios únicos
GROUP BY LaunchSite	Contar lanzamientos por sitio
GROUP BY Class	Contar éxito/fallo
SUM(PayloadMass)	Carga útil total
AVG(Class) GROUP BY Year	Tendencia anual
WHERE LaunchSite LIKE "CCA%"	Filtrar sitios CCA

Folium — Interactive Visual Analytics

- Mapa con sitios de lanzamiento y marcadores históricos.
- MarkerCluster agrupa registros; popup identifica el sitio.
- El HTML interactivo se entrega en `outputs/folium_launch_sites.html`.

Plotly Dash — Interactive Dashboard


- Dropdown para Launch Site.
- RangeSlider para Payload Mass.
- Pie chart de Class.
- Scatter de Payload Mass vs Flight Number.
- El código completo está en `spacex_dash_app.py`.

Predictive Analysis — setup

- X: 90×83 después de one-hot encoding.
- Y: Class.
- StandardScaler.
- `train_test_split(test_size=0.2, random_state=2)`.
- 18 observaciones de prueba.


Predictive Analysis — model results

- Todos los modelos obtuvieron 83.33% en el test de referencia.
- Logistic Regression: validation 84.72%.
- SVM: validation 84.72%.
- Decision Tree: validation 87.50%.
- KNN: validation 84.72%.



Predictive Analysis — confusion matrix

- Referencia de Logistic Regression: $[[3,3],[0,12]]$.
- 15 de 18 predicciones fueron correctas.
- El principal error fue el falso positivo; no se observan falsos negativos en esta matriz.



Conclusion

- El análisis integra todo el flujo de ciencia de datos solicitado.
- La experiencia operacional aparece asociada a mayor éxito.
- Los cuatro modelos empatan en accuracy de prueba en la ejecución de referencia.
- Con solo 18 casos de test, conviene evitar conclusiones demasiado fuertes.

Creativity & Innovation

- Propuesta 1: validación temporal para medir generalización a misiones posteriores.
- Propuesta 2: crear un índice de experiencia del booster usando ReusedCount y Flights.
- Propuesta 3: combinar mapa + dashboard para analizar sitio, payload y éxito.
- Propuesta 4: reportar intervalos de incertidumbre cuando una categoría tenga pocos casos.

GitHub — entrega

- Repositorio: <https://github.com/JesusCH25/testpo>
- Subir la carpeta generada manteniendo notebooks, README, data/ y outputs/.
- Después de subirla, usar la URL del repositorio (no la URL del Pull Request) en el formulario.